

Modelo semi-supervisado de redes neuronales convolucionales equivariantes para la segmentación y clasificación de imágenes histopatológicas


Propuesta de Investigación - Plan de trabajo

Maximiliano Garavito Chtefan

Director:

David Romo Bucheli, Ph.D

Universidad Industrial de Santander
Facultad de Ingenierías Fisicomecánicas
Escuela de Ingeniería de Sistemas e Informática
Bucaramanga
2024



Biomedical Imaging, Vision and Learning Laboratory

Contenido

Resumen	1
Abstract	2
1 Introducción	3
2 Fundamentos y Trabajos Previos	5
2.1 Patología digital	5
2.2 Tipos de aprendizaje de máquina	6
2.3 Redes neuronales profundas	9
2.4 Redes neuronales convolucionales equivariantes	11
2.5 Trabajos Previos en Redes neuronales Equivariantes	16
3 Planteamiento del problema y justificación	18
4 Objetivos	20
4.1 Objetivo General	20
4.2 Objetivos Específicos	20
5 Metodología	21
5.1 Etapa 1. Selección de imágenes histopatológicas anotadas que hayan sido recopiladas para la clasificación y segmentación de estructuras microscópicas	21
5.2 Etapa 2. Formulación e implementación del modelo semi-supervisado basado en una arquitectura de red neuronal convolucional equivariante para la segmentación y clasificación de imágenes histopatológicas	21
5.3 Etapa 3. Evaluación del desempeño del modelo de redes neuronales convolucionales equivariantes sobre un conjunto de validación de imágenes histopatológicas a través de métricas para la clasificación y segmentación de imágenes	22
5.4 Etapa 4. Elaboración del informe final	22
6 Aspectos éticos	23
7 Cronograma	24
8 Presupuesto	25

RESUMEN

Título: Modelo semi-supervisado de redes neuronales convolucionales equivariantes para la segmentación y clasificación de imágenes histopatológicas.¹

Autor: Maximiliano Garavito Chtefan.²

Palabras Clave: Redes neuronales convolucionales equivariantes, imágenes histopatológicas, procesamiento de imágenes, aprendizaje semi-supervisado

Objetivo General: Desarrollar un modelo semi-supervisado de redes neuronales convolucionales equivariantes para la segmentación y clasificación de imágenes histopatológicas.

DESCRIPCIÓN:

La patología digital representa un cambio de paradigma en el enfoque tradicional de diagnóstico médico. Dentro de la medicina contemporánea los avances tecnológicos en curso remodelan constantemente las prácticas de atención médica. Por lo que, el desarrollo de la patología digital es un logro transformador que permite introducir una combinación de dispositivos electrónicos de punta, como los escáneres de láminas histológicas, análisis de datos y experiencia clínica que puede transformar significativamente la forma en que se brinda la atención al paciente.

Dentro de las aplicaciones de la patología digital, una de las que mayor acogida e interés ha provocado han sido las que respectan al cáncer. Esto es debido a que es una de las principales causas de muerte a nivel global. La carga del cáncer aumentará aproximadamente en un 60 % durante las próximas dos décadas, lo que afectará aún más a los sistemas de salud, a las personas y a las comunidades.

Dado esto, se requiere un nuevo enfoque como el uso de modelos de inteligencia artificial (IA), que optimizan y aceleran los métodos actuales. Aunque, se han desarrollado proyectos de aprendizaje automático dentro del ámbito de la patología digital, la limitada disponibilidad de imágenes anotadas y segmentadas obstaculiza los procesos de aprendizaje profundo, pues realizar estos procesos de anotación exigen gran demanda de tiempo y esfuerzo por parte de los patólogos. Hasta ahora los métodos tradicionales de aprendizaje profundo han solucionado estos problemas con el uso de aumento de datos, que consiste en generación de datos nuevos a partir de los que hay, pero este proyecto pretende mostrar el uso de representaciones equivariantes en los modelos de aprendizaje profundo, que permitirían una representación estable y eficaz de imágenes en patología digital.

Por esto, se propone un modelo de aprendizaje profundo semi-supervisado de redes neuronales equivariantes que permitan optimizar el tiempo y los recursos de pre-procesamiento, pero también disminuir las limitaciones que tienen los patólogos al implementar proyectos de análisis automático.

¹ Tesis.

² Facultad de Ingenierías Físico-mecánicas. Escuela de Ingeniería de Sistemas e Informática. Director: David Romo Bucheli, Ph.D

ABSTRACT

Title: Semi-supervised model of equivariant convolutional neural networks for segmentation and classification of histopathological images¹

Author: Maximiliano Garavito Chtefan.²

Keywords: equivariant convolutional neural networks, Histopathological image, digital image processing, semi-supervised learning

General Objective: Develop a semi-supervised model of equivariant convolutional neural networks for the segmentation and classification of histopathological images.

DESCRIPTION:

Digital pathology represents a paradigm shift in the traditional approach to medical diagnosis. Within contemporary medicine, ongoing technological advances are constantly reshaping healthcare practices. Therefore, the development of digital pathology is a transformative achievement that allows for the introduction of a combination of cutting-edge electronic devices, such as histology slide scanners, data analytics, and clinical expertise that can significantly transform the way patient care is delivered. Among the applications of digital pathology, one of the most popular and interesting has been that regarding cancer. This is because it is one of the leading causes of death globally. The burden of cancer will increase by approximately 60 % over the next two decades, further affecting healthcare systems, individuals, and communities.

Given this, a new approach is required, such as the use of artificial intelligence (AI) models, which optimize and accelerate current methods. Although machine learning projects have been developed within the field of digital pathology, the limited availability of annotated and segmented images hinders deep learning processes, since performing these annotation processes requires a great deal of time and effort from pathologists. Until now, traditional deep learning methods have solved these problems by using data augmentation, which consists of generating new data from existing data, but this project aims to show the use of equivariant representations in deep learning models, which would allow a stable and effective representation of images in digital pathology.

For this reason, a semi-supervised deep learning model of equivariant neural networks is proposed that allows optimizing pre-processing time and resources, but also reducing the limitations that pathologists have when implementing automatic analysis projects.

¹ Research Work.

² Faculty of Physics-Mechanics Engineering. School of Systems Engineering and Informatics. Advisor: David Romo Bucheli, Ph.D.

1 Introducción

La patología digital es uno de los avances tecnológicos con mayor impacto para diagnóstico de enfermedades [1], pues a diferencia de la patología tradicional, esta permite el análisis de imágenes sin la limitación de la interacción directa de patólogo-microscopio, lo que además posibilita la colaboración inter-patólogo para diagnósticos complicados. Es importante resaltar las enormes posibilidades que brinda la implementación de este nuevo paradigma dentro del diagnóstico clínico. Es necesario apuntar que, “la adopción de la patología digital estuvo motivada por una doble necesidad. La creciente tasa de expansión de los datos médicos que ha requerido el desarrollo de métodos más eficientes y escalables para la gestión de datos. Además, la búsqueda de una mayor precisión y uniformidad en los diagnósticos ha llevado a la investigación de soluciones basadas en la tecnología” [2]. El anterior es el contexto general dentro del cual el presente proyecto ha surgido, mismo enfocado en la aplicación de la patología digital en el diagnóstico del cáncer, que es el nombre común que recibe un conjunto de enfermedades relacionadas en las que se observa un proceso descontrolado en la división de las células del cuerpo. Pues una de las aplicaciones de la patología digital en la práctica médica y pronóstico para el paciente cuyo mayor impacto tiene, es el diagnóstico de este tipo de enfermedad. Esto se debe a que es uno de los problemas de salud pública con mayor incidencia en el mundo: En Colombia el cáncer fue la segunda causa de muerte durante el periodo 2007-2013. Con aproximadamente 33.538 defunciones anuales, lo que representó el 17,1 % de la mortalidad del país [3] y también la segunda causa de muerte en los Estados Unidos [4]. Por otro lado, la detección del cáncer conlleva costos elevados y demanda rapidez en el diagnóstico para una detección temprana, debido a que esta enfermedad puede progresar de manera agresiva y tener un desenlace mortal para el paciente. Por último, el cáncer presenta la particularidad de que los tejidos presentan alta variabilidad, por lo que requiere de un elevado grado de entrenamiento por parte de patólogos expertos para hacer el diagnóstico. Todo esto hace que el cáncer sea una de las enfermedades que mayores problemas presenta dentro del proceso de diagnóstico. Asimismo, es importante tener en cuenta que el proceso para realizar un diagnóstico de cáncer consiste en tomar una muestra, llamada biopsia, del tejido que presenta neoplasia, para ser preparada en un porta-objetos para su posterior análisis en microscopio por parte de un patólogo. La dificultad de la revisión a profundidad y sistemática de una muestra, hace que la detección se haga inicialmente viendo estructuras a baja magnificación que posteriormente se amplían y estudian a alta magnificación para hacer el diagnóstico apropiado. Sin embargo, aún con el proceso exhaustivo de entrenamiento que reciben los patólogos, existe una significativa variabilidad inter-patólogo en los resultados. Así, patólogos distintos frecuentemente difieren en el diagnóstico de una misma muestra. Por ejemplo, la concordancia sobre el grado tumoral del carcinoma de ovario ha sido reportado con un coeficiente kappa de 0,25 para 664 tumores [5]; El grado

fue moderadamente reproducible en cuatro ensayos ($N = 10, 10, 19, 10$) con muestras del Cooperative Breast Cancer Tissue Resource ($\kappa = 0,50-0,59$) [6]. Por otro lado, en un estudio de 350 pacientes, se encontró que la graduación histopatológica del cáncer de próstata presentó un κ de 0.67 [7], mostrando con esto un elemento subjetivo en el diagnóstico.

Para ayudar a mitigar este problema, en el estado del arte se han propuesto herramientas computacionales que puedan dar soporte al diagnóstico, pero analizar muestras teniendo en cuenta estructuras más pequeñas y más dispersas que podrían pasar desapercibidas para un patólogo (algo de particular interés para los casos de detección temprana de cáncer) presenta retos computacionales particulares, como lo son el manejo de imágenes de $100,000 \times 100,000$ píxeles con una baja densidad de píxeles asociados a un cáncer particular [8] [9]. Debido a lo anterior, la motivación de este proyecto es el desarrollo de modelos automáticos de detección para soportar el diagnóstico en imágenes histopatológicas propendiendo por la disminución de la variabilidad inter-sujeto.

Es importante notar que, bajo un enfoque de entrenamiento supervisado, se requiere de una cantidad elevada de imágenes debidamente anotadas o segmentadas, siendo este proceso de anotación altamente complejo y que además requiere de tiempos prolongados haciéndolo inviable económicamente debido a la cantidad de horas de patólogo profesional que requiere. Lo anterior hace que la cantidad de imágenes debidamente anotadas sea muy limitada, por lo que la respuesta “natural” de hacer redes neuronales grandes y profundas resulte casi imposible en la práctica. Precisamente para solucionar este problema se propone un régimen de entrenamiento semi-supervisado, pues existe la posibilidad de aumentar la cantidad de imágenes sin anotación asociadas a una patología concreta durante el entrenamiento. De esta manera, las imágenes no anotadas pueden servir como un paso no supervisado del entrenamiento, antes de la etapa de entrenamiento supervisado con una cantidad limitada de imágenes anotadas por expertos.

Para resolver este problema de extracción eficiente de información con pocos datos anotados, se propone diseñar una red neuronal convolucional equivariante a la acción del Grupo Euclidiano (rotaciones y reflexiones). Esta decisión se debe a que estas redes (equivariantes a la acción de un grupo) maximizan la extracción de información cuando se conocen simetrías que la señal presenta [10].

En resumen, el presente trabajo pretende implementar y evaluar un modelo de aprendizaje profundo semi-supervisado basado en redes neuronales convolucionales equivariantes para el análisis de imágenes histopatológicas, buscando una representación robusta, aún con una cantidad limitada de datos.

2 Fundamentos y Trabajos Previos

En la presente sección se hace una breve descripción de los aspectos teóricos que sustentan el trabajo de investigación. Esta sección se divide en dos subsecciones: la primera hace una revisión de temas asociados a la patología digital, lo cual incluye, el análisis automático de imágenes histopatológicas; la segunda, hace una revisión sobre lo relacionado con el modelo de redes neuronales equivariantes.

2.1. Patología digital

La patología digital refiere a un conjunto de herramientas y sistemas destinados a la adquisición, gestión y diagnóstico de portaobjetos de patología en un entorno digital (Song et al., 2023)[11]. Inicialmente la revolución de la patología tradicional comenzó por el desarrollo de la imagen completa del portaobjeto. Esto facilitó realizar diagnósticos asistidos por computadora. Pero, actualmente el entrenamiento de algoritmos de inteligencia artificial promete la posibilidad de explorar y extraer información más allá de la percepción visual humana [12].

La idea básica consiste en usar la inteligencia artificial (en adelante IA) para “analizar conjuntos de datos extensos, detectar patrones y ayudar a los patólogos a realizar diagnósticos precisos. La integración de la experiencia humana y el aumento de la IA dio como resultado una disminución de los errores de diagnóstico y una aceleración del proceso de diagnóstico” [2]. Por lo que los adelantos recientes en patología digital con el uso de inteligencia artificial se han podido desarrollar gracias a la previa implementación de la tecnología denominada imagen completa del portaobjeto, la cual, se ha aplicado a una variedad de enfermedades, incluidas patologías de próstata, piel, mama, hígado, colorrectal y riñón [13].

Dentro de la patología digital, la inteligencia artificial han generado toda una explosión de innovaciones que van desde la automatización de tareas diagnósticas rutinarias hasta el descubrimiento de nuevos biomarcadores pronósticos y predictivos de la morfología tisular[14]. Asimismo, estos pueden ayudar con el problema de la variabilidad inter-patólogo en el diagnóstico “los algoritmos de patología digital basados en CNN han demostrado desde entonces un desempeño a nivel de expertos en una serie de tareas de patología propensas a la variabilidad entre observadores, incluyendo, pero no limitada al cáncer de próstata de calificación, contando mitos en el cáncer de mama, clasificación de tumores que comparó en el cáncer colorrectal, o diagnosticar, subtipado y detección de mutaciones genéticas asociadas en el cáncer de pulmón” [14].

Esto se debe a que gracias a la patología digital es posible automatizar las tareas que los patólogos realizan en su práctica diaria permitiéndoles descubrir biomarcadores morfológicos para los resultados clínicos de interés [11]. No obstante aunque, el uso de

inteligencia artificial es fundamental para el progreso de la patología, “su integración en entornos clínicos se ha visto limitada por una serie de obstáculos que incluyen desafíos operativos, técnicos, regulatorios, éticos, financieros y culturales” [14]. Por tal razón, se requieren iniciativas que permitan tener acceso a conjuntos de datos más grandes, bien curados y multimodales acompañados de implementaciones mejoradas de inteligencia artificial que permitan la adopción clínica de herramientas de patología digital [11]. Entre los elementos y características fundamentales de la patología digital se distinguen varios elementos que difieren de la patología convencional, el principal son las Placas virtuales completas o Whole-Slide Imaging (WSI), que a diferencia del análisis convencional de imágenes patológicas -que utiliza cortes finos de la muestra sobre el portaobjeto, los cuales son evaluados por el patólogo para determinar el estado de cada muestra en el mismo momento en que se observa- en patología digital se realiza el proceso de adquisición y digitalización de la muestra en el portaobjetos con el fin de generar imágenes digitales de alta resolución que se conocen como diapositivas o slides.

2.2. Tipos de aprendizaje de máquina

El aprendizaje de máquina abarca una amplia gama de desarrollos recientes de la computación, la estadística y la inteligencia artificial que permiten que las máquinas “aprendan” (y puedan hacer inferencias) en diversos campos aplicados.

Esto quiere decir que sin necesidad de programar la computadora para realizar alguna tarea específica, el aprendizaje de máquina ayuda a la computadora a aprender (o inferir) qué debe hacer en base a la información suministrada para este proceso [15].

En resumen, el aprendizaje de máquina se compone fundamentalmente por tres partes: a) un cálculo computacional, b) un contexto que permite tomar una decisión y c) unos datos de entrada que permiten a la máquina ‘aprender’ o inferir, permitiéndole poder realizar tareas posteriores al entrenamiento [15].

De acuerdo a la tarea a la que se desea entrenar al modelo, la cantidad y tipos de datos que se tienen para el entrenamiento el aprendizaje de máquina se puede dividir en tres grandes categorías:

Aprendizaje supervisado: El aprendizaje de máquina supervisado sirve para predecir etiquetas o segmentaciones a partir de un conjunto de datos que ha sido previamente etiquetado para luego ser usado como datos de entrenamiento [15]. Por su parte, los datos de entrenamiento en este tipo de aprendizaje se dividen en dos grupos: los datos y las etiquetas de los mismos, que usualmente son creadas manualmente por un experto en el tema. Un ejemplo podría ser la segmentación de las células en un WSI realizado por patólogos, como se puede ver en la Figura 2.1.

Aprendizaje no supervisado: En contraposición, el aprendizaje de máquina no supervisado se utiliza cuando la información no está clasificada ni etiquetada [15], ya que, el proceso de etiquetación de datos es costoso y complejo: estimaciones realizadas por estudios enfocados en patología digital revelan que el tiempo para la anotación de WSI




Figura 2.1: Imágenes histopatológicas anotadas por expertos para guiar el aprendizaje (aprendizaje supervisado). En el caso particular de imágenes histopatológicas es poco frecuente que se tenga acceso a numerosas imágenes anotadas.




Figura 2.2: Agrupación de imágenes similares como una forma de aprendizaje no supervisado.

en tareas generales de patología puede variar entre 45 segundos a 360 minutos dependiendo de la complejidad de la tarea[16]. Además, el enfoque no supervisado tiene la ventaja que permite explorar la forma en la que se organizan los datos, permitiendo encontrar estructuras ocultas en conjuntos de datos sin etiquetar [15]. Siendo así que en este caso el algoritmo no busca la salida correcta, ya que no se cuenta con etiquetas. Este tipo de algoritmos permite extraer información valiosa[15], como por ejemplo con los algoritmos de agrupación (ver Figura 2.2), asociación y los de reducción de dimensionalidad, de esta manera se busca encontrar similitudes entre los datos permitiendo crear agrupaciones y categorías o encontrar representaciones de baja dimensionalidad que sirvan para reconstruir los datos de entrada con poca información.

Aprendizaje semi-supervisado: Un tercer tipo de aprendizaje de máquina intermedio entre los dos anteriores es el de aprendizaje de máquina semi-supervisado, en los casos

donde hay muchos datos no anotados y pocos datos anotados (ver Figura 2.3. Este procedimiento es usado en casos en los cuales los datos son variados porque combinan datos etiquetados y no etiquetados para el entrenamiento de maquina permitiendo el uso del aprendizaje supervisado y el no supervisado dependiendo de las características específicas de los datos en cuestión [15]. Por ejemplo, se usan datos que presentan o pocas etiquetas o sin etiquetar [15]. Por consiguiente, este tipo de aprendizaje de máquina es implementado para mejorar significativamente la precisión del modelo en vez de limitarse al uso de pocos datos etiquetados [15].




Figura 2.3: Se muestra un ejemplo de modelo de aprendizaje no supervisado, donde la tarea del modelo es aprender a segmentar de células de manera supervisada (con imágenes anotadas por expertos), pero el modelo se ayuda de un proceso no supervisado de clustering para mejorar su predicción (con imágenes no anotadas). Es frecuente en el contexto de la patología digital tener acceso a una cantidad numerosa de imágenes no anotadas y una baja cantidad de imágenes anotadas, por lo que un modelo semi-supervisado podría ser ideal.

2.3. Redes neuronales profundas

Una red neuronal en el contexto del aprendizaje automático es un modelo computacional inspirado en la estructura y funcionamiento de las neuronas interconectadas del cerebro humano, en medida que es un tipo de algoritmo que consta de capas de nodos o neuronas conectados de manera jerárquica. Como su nombre indica, las neuronas son los componentes básicos de una red neuronal. Cada neurona procesa las señales de entrada y sus salidas se envía a la siguiente capa de neuronas. Las conexiones internas entre neuronas tienen un peso que determina cuánto influye cada señal de entrada. Después de multiplicar la entrada por el peso, se aplica una función de activación a la suma ponderada de las entradas. Las funciones de activación más comunes son la sigmoide, la tangente hiperbólica (tanh), la Unidad Lineal Rectificada (ReLU) y la función softmax. Para una representación gráfica de una red neuronal, ver la Figura 2.4.




Figura 2.4: Ejemplo de una red neuronal profunda: la capa de entrada recibe 4 valores, luego hay 4 capas ocultas, donde cada neurona aplica una función ReLU. Finalmente la capa de salida aplica una función sigmoide y entrega un valor.

Se les llama profundas a estas redes debido a que las neuronas se organizan en capas. Normalmente, una red neuronal consta de una capa de entrada, una o más capas ocultas apiladas en sucesión y una capa de salida. La capa de entrada recibe los datos iniciales, las capas ocultas los procesan y la capa de salida produce el resultado final. Durante la fase de entrenamiento, la red neuronal recibe datos de entrada, los pasa a través de las capas mediante un proceso llamado *feedforward*, calcula la salida y luego la compara con la salida esperada. Luego utiliza una técnica llamada *backpropagation* para ajustar los pesos y sesgos con el fin de minimizar la diferencia entre los resultados previstos y reales. Las redes neuronales aprenden de ejemplos ajustando sus pesos y sesgos mediante algoritmos de entrenamiento como el gradiente descendiente, donde la red intenta minimizar una función de costo o pérdida que mide la diferencia entre los resultados previstos y reales.

De particular interés para este proyecto son las redes neuronales convolucionales (*Convolutional Neural Network*, CNN), las cuales son un tipo especializado de red neuronal profunda diseñada para procesar datos con una estructura geométrica en forma de cuadrícula, como imágenes o secuencias de audio. Las CNN son particularmente efecti-

vas en tareas de visión por computadora, pero también se han aplicado con éxito a otros campos de aplicación tales como el procesamiento del lenguaje natural y el análisis de audio. Las CNN están inspiradas en la organización de la corteza visual animal, donde las neuronas responden a regiones superpuestas en el campo visual. Por analogía, la operación de convolución es una forma de mezclar dos funciones, se puede visualizar como voltear y luego deslizar una función sobre la otra, anotando el resultado en cada punto. Un ejemplo común consiste en aplicar un filtro a una imagen, como se puede ver en la Figura 2.5.




Figura 2.5: Ejemplo de convolución discreta para un filtro que se desliza sobre la grilla magenta. La función del filtro la transforma a otro valor (color verde). Se puede ver que el proceso es local: solo se toman elementos que conforman un vecindario en la grilla para generar el resultado.

En general la convolución de dos funciones $f, g \rightarrow \mathbb{R}$ se escribe como $(f * g)(x) \rightarrow \mathbb{R}$ que es otra función y se define como la integral del producto de ambas funciones después de desplazar una de ellas una distancia t de la siguiente manera:

$$(f * g)(x) = \int_{-\infty}^{\infty} f(y)g(x - t)dt \quad (2.1)$$

El caso discreto es similar al caso continuo pero ahora las funciones $f[m], g[m] \rightarrow \mathbb{Z}$ reciben valores discretos y la integral es reemplazada por una sumatoria y, así mismo, el desplazamiento sobre la variable $[n]$ también es discreto, define como:

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m]g[n - m] \quad (2.2)$$

Es importante tener en cuenta que las CNN, al usar filtros, son inherentemente equi-variantes a la traslación, lo que implica que estas pueden reconocer patrones independientemente de su posición en la entrada. Esta propiedad se logra mediante capas convolucionales, que comparten pesos entre posiciones espaciales. Como resultado, las CNN no son afectadas por las traslaciones y pueden identificar eficazmente objetos en imágenes independientemente de su ubicación, una propiedad altamente deseable en datos estructurados, como es el caso de las imágenes. Debido al a priori que se tiene sobre la estructura geométrica de las imágenes, las CNN también pueden explotar el

concepto de compartir parámetros, al que se aplica el mismo conjunto de pesos en diferentes ubicaciones espaciales. Esto reduce significativamente la cantidad de parámetros en la red, lo que la hace más eficiente desde el punto de vista computacional y más fácil de entrenar, especialmente cuando se trata de entradas de alta dimensión como imágenes.

2.4. Redes neuronales convolucionales equivariantes

Las redes neuronales convolucionales hacen uso de la simple observación según la cual las características geométricas locales en imágenes no cambian si son trasladadas, esto es, son equivariantes a la traslación, haciéndolas tremendamente eficientes para tareas de procesamiento de imágenes [17]. Para ejemplificar, si se entrena una red convolucional en la segmentación de gatos y el gato en la imagen cambia de posición, la segmentación debe cambiar de la misma manera que la posición del gato, ya sea traslación, rotación o reflexión.

Con el fin de visualizar lo dicho anteriormente se presentan las siguientes imágenes de un gato y una sección de WSI que han sido transformadas de varias maneras, sin perder la información que contienen ver Figura 2.6 (para mayor claridad los ejemplos siguientes se harán con imágenes naturales, como la del gato).



Figura 2.6: Imagen sobre la que se aplican diferentes transformaciones.

Por analogía, una red neuronal debe poder clasificar o segmentar la imagen del gato sin importar la transformación que se realice. Ver Figura 2.7.

A estas funciones caracterizadas por transformaciones que conmutan con la aplicación de la función (en este caso la red neuronal convolucional) se les llama equivariantes, en este caso, al grupo de simetría de las traslaciones [17]. Es decir, el proceso de aplicar una transformación de simetría y luego calcular la función que produce el mismo resultado que calcular la función y posteriormente aplicar la transformación.

En el caso particular de datos que va ser usado en el presente proyecto, esto es - las imágenes histopatológicas, estas se caracterizan en que además de contar con este tipo




Figura 2.7: En (a) se muestra cómo la clasificación puede ser invariante. En (b) se muestra cómo la segmentación puede ser equivariante.

de simetría traslacional, no presentan una orientación preferida, es decir, un conglomerado celular presenta las mismas características morfológicas sin importar si la imagen es reflejada o rotada arbitrariamente y, por lo tanto, en la práctica, un patólogo puede obtener el mismo diagnóstico sin siquiera haber notado que la imagen ha sido previamente rotada. Esta característica de las imágenes histopatológicas las hace diferente de otros tipos de imágenes que sí presentan una orientación preferida, como es el ejemplo claro de los dígitos y en particular los números: 6 y 9, como se aprecia en la Figura 2.8.



Figura 2.8: Un ejemplo de que no todas las imágenes tienen simetría rotacional, en particular los dígitos 6 y 9 se diferencian por una rotación de 180°

Como en el caso de las redes neuronales convolucionales usuales, aprovechar esta simetría ofrece un sesgo inductivo fuerte a los modelos de aprendizaje ya que reduce los grados de libertad que los modelos y sus parámetros pueden tener y -tal como en las redes convolucionales usuales,- permite hacer weight sharing lo que las hace menos propensas a overfitting, permitiéndoles converger más rápidamente con una menor cantidad de datos [18]. De hecho, uno de los métodos usado para lograr estas mismas características en una red consiste en el conocido data augmentation con transformaciones geométricas del dataset, sin embargo, el uso de estas simetrías concretamente en

este contexto equivariante de imágenes histopatológicas es estrictamente más efectivo que realizar data augmentation con transformaciones geométricas [10].

Grupo Para poder describir una simetría en lenguaje matemático usualmente se habla de grupos. Un grupo en matemáticas hace referencia a un conjunto no vacío creado a partir de una operación que combina cualquier par de elementos que sean parte del grupo para obtener un tercer elemento que también cumplirá con las condiciones de dicho grupo.

Los grupos son usados en diversas áreas de la matemática. Especialmente, en la geometría sirven para agrupar las simetrías o diferentes transformaciones geométricas con respecto a un objeto geométrico determinado. Lo anterior quiere decir que las simetrías de un objeto geométrico forman el grupo de simetrías, mientras que cierta transformación tal como la rotación forma el grupo de rotaciones en una esfera, por ejemplo.

Para efectos prácticos un objeto geométrico puede ser una línea o una esfera, pero los grupos se pueden definir de manera más abstracta, lo que permite hablar de otros y más diversos tipos de simetrías. De acuerdo a lo anterior, para que un grupo dado sea considerado como tal requiere que sea un conjunto que contenga al menos las siguientes reglas de combinación, también conocidas como axiomas del grupo. Para todo $a, b, c, e \in G$ un grupo, usando como notación usual la de la operación de multiplicación se tiene: La operación es asociativa

$$(ab)c = a(bc) \quad (2.3)$$

Tiene un elemento de identidad e .

$$ea = ae = a \quad (2.4)$$

Cada elemento del conjunto tiene un elemento inverso.

$$a^{-1}a = aa^{-1} = e \quad (2.5)$$

Grupo de Simetría La forma en que el concepto de grupo captura la idea de simetría es por medio del concepto de grupo de simetría. El grupo de simetría es un grupo de acciones o transformaciones que al aplicarse a un objeto matemático no modifican sus características generales, es decir, se mantiene invariante. Un ejemplo de lo anterior son las rotaciones de una esfera. Es así como los objetos que presentan simetrías pueden ser objetos geométricos, imágenes, ecuaciones en física o patrones en general. Así mismo, el elemento de un grupo puede actuar sobre un conjunto o espacio, un concepto altamente correlacionado con la simetría, pues la simetría es un tipo de invarianza en donde un objeto no cambia después de ser transformado por alguna acción particular.

Para el presente trabajo de investigación, los grupos a considerar son grupos de simetría, en particular, las simetrías que tienen las imágenes histopatológicas: traslación, rotación y reflexión, incluidas sus combinaciones. Algo que puede sonar similar al concepto de data augmentation, donde a un conjunto de datos se les aplica este mismo tipo de transformaciones geométricas para aumentar el tamaño del conjunto; pero en el caso de las redes equivalentes se desea agregar esta información de grupo de simetría directamente en la red, no solo en los datos con los que se entrena.

Mapas equivariantes o funciones equivariantes Son funciones para las cuales la entrada y la salida reciben la misma acción del grupo (la acción del grupo conmuta con la aplicación de la función). Esto quiere decir, que es posible ‘factorizar’ la acción de un grupo de la función. Formalmente, la equivarianza se puede describir como:

Sea $g \in G$ elemento de un grupo que actúa en X, Y , el dominio y codominio de una función f . Se dice que esta función $f: X \rightarrow Y$ es equivariante a la acción del grupo G , si para todo g :

$$f(g \cdot x) = g \cdot f(x) \quad (2.6)$$

Esta propiedad también se puede ver como un diagrama conmutativo:

$$\begin{array}{ccc} X & \xrightarrow{g \cdot} & X \\ f \downarrow & & \downarrow f \\ Y & \xrightarrow{g \cdot} & Y \end{array}$$

Convolución en grupos La convolución en grupos es una operación similar a la convolución tradicional discutida anteriormente, solo que ahora son funciones definidas en un grupo $f, g \rightarrow G$. Estas convoluciones presentan abundantes características similares a las tradicionales, algo semejante a mezclar dos funciones, solo que ahora definidas en un grupo (de simetría, para este trabajo), lo que permite aprovechar las simetrías que tiene la señal, pues además de las características usuales de la convolución tradicional, esta convolución en grupos permite usar la estructura que dan los grupos, permitiendo equivarianza, esto es, la aplicación del grupo a la convolución conmuta con la aplicación a la función (derecha o izquierda de la convolución, pues de manera general la multiplicación en grupos no es conmutativa) esto se puede ver en la Figura 2.9. Sumado a esto, en [19] se demostró que la convolución en grupos no solo es una condición suficiente para mapas o funciones equivariantes, sino una condición necesaria. Por lo que, de manera general, las redes neuronales equivariantes hacen uso de convoluciones en grupos.

La convolución en grupos, entonces, se define similarmente a la tradicional, de la siguiente manera:

$$(f * g)(x) = \int_G f(y) g(y^{-1}x) d\lambda(y) \quad (2.7)$$

Donde $d\lambda$ es una medida (measure en inglés) -por la izquierda o por la derecha solamente, pues no se puede asumir conmutatividad de la operación del grupo- de Haar y x, y pertenecen a un grupo G . Se puede notar el alto grado de similitud con la convolución tradicional y, de hecho, si tomamos $(\mathbb{R}, +)$ como un grupo G (números reales con la operación suma), se obtiene la convolución tradicional completa.

Este tipo de convolución tiene la propiedad importante de que la acción del grupo (por la izquierda) L_h a la función f conmuta con la convolución, es decir:




Figura 2.9: Ejemplo de la equivarianza de la convolución en grupo de simetría a las rotaciones de 60° . El filtro se desliza sobre el hexágono y va transformando los colores: no importa si primero se rota el hexágono de entrada (imagen izquierda), o si se rota el resultado de la convolución (imagen derecha). Como resultado, el gradiente de color en el hexágono de salida es el mismo.

$$L_h(f * g) = (L_h f) * g \quad (2.8)$$




Figura 2.10: Los hexágonos tienen simetrías rotacionales de 60° , por lo que el grupo de rotaciones de 60° actúa como un grupo de simetría que actúa sobre los hexágonos. También se puede observar como una función definida en un hexágono (en este caso representada por el gradiente de color) cumple con el diagrama conmutativo que requiere la equivarianza: si se fija una función g (que al igual que f se representa como un gradiente de color) con la que se realiza la convolución, se puede observar cómo es equivariante primero rotar el hexágono con la acción del elemento del grupo L_h , una rotación de 60° o primero realizar la convolución $f * g$ y luego aplicar la acción del grupo.

Esta es justamente la propiedad de equivarianza que se busca y que presenta la convolución en grupos. Esto se puede ver fácilmente en la figura 2.10.

2.5. Trabajos Previos en Redes neuronales Equivariantes

En la presente sección se presentan los avances más relevantes dentro del estado del arte actual referente a la teoría, implementación y uso de redes neuronales equivariantes en general y aplicados en imágenes histopatológicas en particular.

Una de las primeras descripciones generales del uso de convoluciones en grupos para obtener equivarianza se puede ver en “Group Equivariant Convolutional Network” de Cohen & Welling en 2016 [20], donde realizaron una descripción teórico-matemática detallada de qué es una convolución en un grupo y se explican algunos detalles para su discretización en código, presentando un nuevo tipo de capa que usa convoluciones en grupos discretos para obtener equivarianza. También muestran resultados del estado del arte en benchmarks comunes como lo son el dataset MNIST rotado y CIFAR10 (2.28 %error y 4.19 % y. 6.46 % en CIFAR10 aumentado y sin aumentar).

Además, Cohen & Welling también son los encargados de describir la teoría de los filtros orientables para el uso de las redes neuronales convolucionales bajo la teoría de la equivarianza en grupos en “Steerable CNNs” [21]. Una teoría que será usada para la implementación de la CNN en las imágenes histopatológicas en la presente tesis. En este trabajo, de nuevo obtuvieron resultados del estado del arte incluso bajo regímenes de entrenamiento con pocos datos, comparando con ResNet y redes que usan transfer learning. Para este trabajo Cohen & Welling se basaron en teoría tradicional de filtros orientables (steerable filters). En particular, Freeman & Adelson (1991) son los investigadores que inicialmente introducen la teoría clásica de los filtros orientables para visión por computador y detalles de su implementación en código en su trabajo inaugural: “The design and use of steerable filters” [22].

Por otra parte, avances importantes en el campo relevantes para este trabajo de tesis, como los llevados a cabo por Elesedy & Zaidi en 2021 en su trabajo “Provably Strict Generalisation Benefit for Equivariant Models” [10] donde se encargan de demostrar formalmente que las redes neuronales equivariantes son estrictamente mejores y más eficientes en el entrenamiento y generalización con datos que son equivariantes a la acción de un grupo, comparado con otros métodos como data augmentation. En particular, para imágenes, que presentan equivarianza traslacional, se obtienen las mismas redes convolucionales usuales.

De manera más reciente, Cesa et al. [18] muestran el proceso matemático para la construcción de redes convolucionales equivariantes para el grupo euclidiano y todos sus subgrupos. Además implementan en código este tipo de redes de manera general en una librería de Pytorch. Por otra parte, generalizan el teorema de Wigner-Eckart para todos los grupos compactos para poder encontrar representaciones irreducibles de estos grupos, que es un paso fundamental en la implementación de este tipo de redes.

Cabe destacar que durante ese mismo 2021, Weiler, Maurice, et al. [23] presentaron la que sería la formulación teórica más general de una red equivariante, requiriendo solamente equivarianza a los gauges de variedades riemannianas e implementan una red neuronal convolucional en una banda de Möbius en “Coordinate Independent Convolutional Networks–Isometry and Gauge Equivariant Convolutions on Riemannian Ma-

nifolds”.

Así mismo, Bekkers, et al. [24], muestran el uso de redes equivariantes para imágenes médicas (incluido imágenes histopatológicas) en el trabajo denominado “Rotation Covariant Convolutional Networks for Medical Image Analysis”. En este artículo se implementa una red neuronal convolucional equivariante al grupo euclidiano (el grupo de traslaciones, rotaciones y reflexiones), obteniendo resultados comparables con el estado del arte sin necesidad de hacer uso de la técnica de aumento de datos. Entre las imágenes médicas con las que experimentan con este modelo se encuentran datasets de imágenes histopatológicas para detección de mitosis, segmentación de vasos sanguíneos en retícula y segmentación de células de imágenes de microscopio de electrones. En el caso de este trabajo, se usan rotaciones discretas y empíricamente se observa que entre más fino es el sampling de las rotaciones, por ejemplo tomando rotaciones de 30° en vez de 90° , se mejoran los resultados y se disminuye la varianza.

Por último, es menester citar dos trabajos que son parte de los antecedentes del presente proyecto: En primer lugar, de 2018 “Rotation Equivariant CNNs for Digital Pathology” de Veeling, et al. [25] muestran que las imágenes histopatológicas son invariantes a la reflexión y a la rotación e implementan una red neuronal convolucional equivariante a la rotación de 90° , mostrando que utilizar redes equivariantes para imágenes histopatológicas mejora sustancialmente el rendimiento incluso con menos parámetros. En segundo lugar, de 2020 “A Dynamic Group Equivariant Convolutional Networks for Medical Image Analysis” de Li, Cao, & Cao. [26] donde desarrollan convoluciones dinámicas en el framework de las redes equivariantes. Estos autores generalizan las convoluciones dinámicas, que es una forma de *atención*, sobre los filtros de redes convolucionales. En este caso, también utilizan imágenes histopatológicas de cáncer de mama para validar un modelo de red convolucional dinámica y equivariante y obtienen resultados del estado del arte. Como se puede ver, existen métodos equivariantes para clasificación supervisada. También existen una importante cantidad de métodos no supervisados que no son equivariantes. Explorar esta idea en enfoques de aprendizaje no supervisado, como se plantea en este proyecto, puede resultar interesante, pues el sesgo inductivo asociado a la equivarianza podría llevar a representaciones más efectivas de las imágenes histopatológicas.

3 Planteamiento del problema y justificación

La histología es una de las ramas fundamentales de la medicina ya que esta rama de la ciencia esta encargada en el estudio de la anatomía de los seres humanos desde una perspectiva microscópica. Es así como la histología ha posibilitado avances cruciales para el diagnóstico de enfermedades a través de la identificación de síntomas a nivel microscópico en el campo de la patología médica. Esto se debe a que la capacidad de examinar los tejidos a nivel celular ha ayudado a comprender la naturaleza y el desarrollo de las enfermedades. En el caso específico de patologías asociadas al cáncer, la histología ha desempeñado un papel vital identificando alteraciones morfológicas y celulares asociadas con los diferentes tipos de tumores.

En la actualidad, la digitalización de imágenes histopatológicas ha permitido el desarrollo de la patología digital. La adquisición digital de láminas histológicas completas permite su almacenamiento, análisis y distribución de manera eficiente. Esta transformación tecnológica ha superado las limitaciones tradicionales de la patología facilitando el acceso remoto a las imágenes y promoviendo la colaboración entre profesionales de la salud en diferentes ubicaciones geográficas. Ambos aspectos prometen un avance significativo en el proceso de diagnosis de cáncer.

Entre las herramientas computacionales asociadas a la patología digital, los sistemas de apoyo al diagnóstico prometen mejorar la precisión y la eficiencia en la toma de decisiones médicas. La posibilidad de aplicar herramientas automáticas de análisis ha impulsado la investigación y el desarrollo de enfoques más avanzados para la detección y clasificación de enfermedades usando información microscópica, incluyendo el cáncer. Además, este tipo de herramientas ayudarían a reducir la alta variabilidad inter e intra observador en el diagnóstico de este tipo de imágenes.

El análisis automático de imágenes histopatológicas representa un avance en el futuro en la medicina diagnóstica. Sin embargo, los alcances de la patología digital en la actualidad está limitada por la cantidad reducida de datos anotados por expertos. Esto se debe a que recolectar imágenes histopatológicas y realizar una anotación manual implica el análisis detallado de patólogos expertos - un proceso inherentemente largo y altamente costoso.

Para realizar el análisis automático de imágenes se han utilizado diferentes tipos algoritmos entre los que han destacado las redes neuronales profundas. Estas redes, en vez de realizar cálculos complejos y computacionalmente exigentes, permiten realizar operaciones simples pero concatenadas de forma profunda y que pueden ser ejecutadas en paralelo, disminuyendo así el tiempo de entrenamiento y de ajuste de parámetros. A cambio, necesitan gran cantidad de datos para tener una precisión adecuada en las predicciones. En general, las redes neuronales no pretenden fijar un proceso de extracción

de características, sino aprender una representación adecuada que permita realizar un análisis automático.

Entre las redes neuronales para el procesamiento de imágenes, se destaca el uso de redes neuronales convolucionales que han sido revolucionarias en la medida en que son más eficientes en la cantidad de parámetros a aprender, pues aprovechan la característica de que muchos datos, en particular las imágenes, tienen información que es altamente local (por ejemplo los píxeles en una imagen tienen relación con otros píxeles adyacentes pero no con los píxeles más apartados), esto hace que requieran menos datos comparado con las redes neuronales tradicionales. Si bien el rendimiento es considerablemente mejor usando la información geométrica de estos datos, muchas observaciones son necesarias y, lamentablemente, no se aprovechan todas las simetrías que imágenes en un campo específico puedan ofrecer. Por esa razón se suele utilizar el proceso de “data augmentation”, que implica generar nuevas imágenes a partir del dataset al que se tiene acceso aplicando diversas transformaciones geométricas a las imágenes originales.

Aplicar data augmentation es ineficiente porque aumenta la cantidad de tiempo para realizar el entrenamiento, dado que, se requiere un trabajo adicional en la preparación de dataset o el preprocesamiento. Además, este procedimiento consume mayor cantidad de recursos computacionales.

Por tal motivo, en el presente trabajo de tesis se propone el uso de redes neuronales equivariantes como un método para mejorar la aplicación de las redes neuronales convolucionales a las imágenes histopatológicas. Estas imágenes tienen más simetrías que las imágenes naturales pues no tienen una orientación natural, esto es, presentan simetrías rotacionales y de reflexión, además de la traslacional. En este sentido, las redes neuronales equivariantes pueden usar de mejor manera diferentes simetrías. Esto permitiría extraer más información sin necesidad de aumentar los datos como sucede en los modelos tradicionales de aprendizaje automático. También se propone un enfoque semi-supervisado, pues si bien hay datasets anotados por expertos, hay una cantidad enorme de imágenes no anotadas que se pueden explotar para mejorar el rendimiento de los modelos.

Esto nos lleva a formular la siguiente pregunta de investigación:

¿Puede un modelo semi-supervisado de redes neuronales convolucionales equivariantes obtener representaciones a través de un entrenamiento efectivo en comparación con modelos tradicionales (sin propiedad de equivarianza a la rotación, traslación y reflexión) entrenados en un régimen completamente supervisado para tareas de segmentación y clasificación de imágenes histopatológicas?

4 Objetivos

4.1. Objetivo General

Desarrollar un modelo semi-supervisado de redes neuronales convolucionales equivariantes para la segmentación y clasificación de imágenes histopatológicas.

4.2. Objetivos Específicos

- Seleccionar un conjunto de datos de imágenes histopatológicas anotadas que hayan sido recopiladas para la clasificación y segmentación de estructuras microscópicas.
- Formular e implementar un modelo semi-supervisado basado en una arquitectura de red neuronal convolucional equivariante para la segmentación y clasificación de imágenes histopatológicas.
- Evaluar el desempeño del modelo de redes neuronales convolucionales equivariantes sobre un conjunto de validación de imágenes histopatológicas a través de métricas para la clasificación y segmentación de imágenes.

5 Metodología

Para el desarrollo del presente trabajo de investigación se propone una metodología en cuatro etapas.

De cada etapa se desglosa un grupo de actividades y se evidencia el cumplimiento por medio del informe final.

5.1. Etapa 1. Selección de imágenes histopatológicas anotadas que hayan sido recopiladas para la clasificación y segmentación de estructuras microscópicas

En la primera etapa se realizará una minuciosa revisión de diferentes datasets de imágenes histopatológicas para seleccionar los que permitan entrenar el modelo semi-supervisado. En este caso, se priorizarán datasets que estén completos y anotados para realizar tareas de clasificación o segmentación de estructuras microscópicas.

- Revisión de repositorios con datasets de imágenes histopatológicas que hayan sido anotadas.
- Filtrado de datasets de repositorios revisados.
- Selección de conjunto de datasets válidos y acordes para entrenar el modelo semi-supervisado.

Plan de mitigación: En la eventualidad de no contar con la posibilidad de emplear datos propios como conjunto de datos primario, las actividades se ejecutarán empleando conjuntos de datos de acceso público.

5.2. Etapa 2. Formulación e implementación del modelo semi-supervisado basado en una arquitectura de red neuronal convolucional equivariante para la segmentación y clasificación de imágenes histopatológicas

En esta etapa se formulará e implementará el modelo de aprendizaje profundo basado en redes neuronales convolucionales equivariantes de acuerdo a los datasets seleccionados.

- Revisión de modelos de segmentación y clasificación de imágenes histopatológicas, arquitecturas e implementaciones disponibles
- Selección de la arquitectura de red neuronal convolucional equivariante adecuada para la segmentación y clasificación de imágenes histopatológicas.
- Implementación del modelo de aprendizaje profundo basado en redes neuronales convolucionales equivariantes a partir de la arquitectura seleccionada.
- Entrenamiento del modelo de aprendizaje profundo basado en redes neuronales convolucionales equivariantes con los datasets seleccionados.

Plan de mitigación: En la eventualidad de no poder implementar un modelo semi-supervisado, se optaría por escoger entre un modelo de aprendizaje supervisado o uno no supervisado y se realizaría su respectiva implementación.

5.3. Etapa 3. Evaluación del desempeño del modelo de redes neuronales convolucionales equivariantes sobre un conjunto de validación de imágenes histopatológicas a través de métricas para la clasificación y segmentación de imágenes

En esta etapa del proyecto se busca evaluar el modelo a través de métricas apropiadas para la clasificación y segmentación de imágenes.

- Identificar las métricas más usadas en la clasificación y segmentación de imágenes.
- Seleccionar las métricas más apropiadas para el modelo semi-supervisado.
- Evaluación del modelo semi-supervisado mediante las métricas seleccionadas.
- Mediante gráficas de Curvas de Entrenamiento y Validación (Pérdida y Exactitud), Matriz de Confusión, Receiver-operating characteristic curve (ROC) y Area under the curve (AUC).

Plan de mitigación: En la eventualidad de no poder evaluar el desempeño del modelo semi-supervisado se evaluaría por separado la parte no-supervisada y por otro lado, la parte supervisada.

5.4. Etapa 4. Elaboración del informe final

En esta etapa final se termina la elaboración del informe y se hacen todas las correcciones de estilo, al mismo tiempo que se validan resultados.

6 Aspectos éticos

Este proyecto de investigación se adherirá tanto en su diseño como en la ejecución a las regulaciones nacionales e internacionales existentes en cuanto a investigación biomédica, siguiendo los lineamientos de Buenas Prácticas Clínicas del Comité Internacional de Armonización y los principios éticos de la Declaración de Helsinki (Asociación Médica Mundial, 2017)[27].

Con respecto a los principios éticos de investigación y lineamiento con las pautas establecidas por la CIOMS en 1991 (Council for International Organizations of Medical Sciences[28], 1991) se realizan las siguientes aclaraciones: 1) al no realizarse intervenciones en pacientes, modificar su práctica de atención clínica o de alguna manera intervenir en la evolución y los desenlaces (se analizan datos de pacientes que ya fueron atendidos), no existe espacio para posibles intervenciones de riesgo para el paciente (preservación del principio de beneficencia y no maleficencia en su elemento común de no exponer el paciente a riesgo); 2) el respeto de los participantes, en conexión además con la confidencialidad, son protegidos y asegurados también por este estudio pues no se recolecta información sensible de los pacientes que les pueda generar estigmatización, además de que la base de datos no incluye de ninguna forma identificadores personales (nombre, dirección de residencia, teléfono) con los cuales se pueda individualizar a quien corresponde cada registro; 3) el objetivo mismo del estudio no solamente asegura el respeto por el principio de justicia sino que busca su realización de manera activa teniendo en cuenta los lineamientos de la OMS mencionados: “[...]Deben diseñarse estudios para obtener conocimiento que beneficie a la clase de personas de las cuales los sujetos son representativos...”, ya que la finalidad misma de este protocolo es obtener conocimiento y poder ofrecer a futuros pacientes la posibilidad de mejoramiento en las estrategias diagnósticas y terapéuticas a las cuales son sometidos.

7 Cronograma

Actividad	Mes							
	1	2	3	4	5	6	7	8
1. Selección de conjunto de datos de imágenes de histopatología								
a. Revisión del estado del arte en redes neuronales equivariantes y redes neuronales aplicadas a imágenes histopatológicas								
b. Caracterización de las diferentes bases de datos								
c. Selección de imágenes para el proceso de aprendizaje semi-supervisado								
2. Selección estrategia semi-supervisada								
a. Revisión del estado del arte en estrategias semi-supervisadas								
b. Caracterización de estrategias usadas en el análisis semi-supervisado de imágenes de histopatología								
c. Definición de métricas para la evaluación de la calidad de las clasificaciones obtenidas con estrategias semi-supervisadas								
d. Selección de una estrategia semi-supervisada para la caracterización de imágenes histopatológicas								
3. Ejecución de experimentos								
a. Identificar métrica apropiada para el entrenamiento de la red neuronal								
b. Programar red neuronal y ejecutar experimentos								
c. Obtener resultados cualitativos y cuantitativos								
5. Elaboración del informe final								

8 Presupuesto

Concepto	Descripción	Fuente de	Valor de referencia*	Cantidad	Precio estimado
Director	Profesor de planta	Especie	\$305.000 por hora	12/h al mes por 8 meses	\$29.280.000
Autor	Estudiante de pregrado	Efectivo (Financiación estudiantil)	1 SMMLV por mes	12 meses	\$13.920.000
Base de Datos Bibliográfica	Contrapartida UIS	Especie	\$0.000.000 al año	1 año	\$20.000.000
Insumos	Papelería	A cargo del autor	-	-	\$200.000
Transporte	Traslados a la universidad	A cargo del autor	-	-	\$1.000.000
TOTAL					\$64.400.000

* Valores tomados de los rubros presupuestales estipulados por la Vicerrectoría de Investigación y Extensión de la Universidad Industrial de Santander.

Bibliografía

- [1] J. D. Pallua, A. Brunner, B. Zelger, M. Schirmer, and J. Haybaeck, “The future of pathology is digital,” vol. 216, no. 9, p. 153040.
- [2] N. Kiran, F. Sapna, F. Kiran, D. Kumar, F. Raja, S. Shiwlani, A. Paladini, F. Sonam, A. Bendari, R. S. Perkash, F. Anjali, and G. Varrassi, “Digital pathology: Transforming diagnosis in the digital age,” vol. 15, no. 9, p. e44620. [Online]. Disponible: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10547926/>
- [3] Pardo C, de Vries E, Buitrago L, and Gamboa O, “Atlas de mortalidad por cáncer en colombia,” vol. 1, p. 124. [Online]. Disponible: https://www.ins.gov.co/TyS/programas-de-calidad/Documentos%20Programa%20EEDDCARIO/ATLAS_de_Mortalidad_por_cancer_en_Colombia.pdf
- [4] H. Sung, J. Ferlay, R. L. Siegel, M. Laversanne, I. Soerjomataram, A. Jemal, and F. Bray, “Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries,” vol. 71, no. 3, pp. 209–249. [Online]. Disponible: <https://acsjournals.onlinelibrary.wiley.com/doi/10.3322/caac.21660>
- [5] R. K. Matsuno, M. E. Sherman, K. Visvanathan, M. T. Goodman, B. Y. Hernandez, C. F. Lynch, O. B. Ioffe, D. Horio, C. Platz, S. F. Altekruse, R. M. Pfeiffer, and W. F. Anderson, “Agreement for tumor grade of ovarian carcinoma: analysis of archival tissues from the surveillance, epidemiology, and end results residual tissue repository,” vol. 24, no. 4, pp. 749–757.
- [6] J. S. Meyer, C. Alvarez, C. Milikowski, N. Olson, I. Russo, J. Russo, A. Glass, B. A. Zehnbauer, K. Lister, R. Parwaresch, and Cooperative Breast Cancer Tissue Resource, “Breast carcinoma malignancy grading by bloom-richardson system vs proliferation index: reproducibility of grade and advantages of proliferation index,” vol. 18, no. 8, pp. 1067–1078.
- [7] Prostate needle biopsies: interobserver variation and clinical consequences of histopathological re-evaluation - PubMed. [Online]. Disponible: <https://pubmed.ncbi.nlm.nih.gov/21492223/>
- [8] M. K. K. Niazi, A. V. Parwani, and M. Gurcan, “Digital pathology and artificial intelligence,” vol. 20, no. 5, pp. e253–e261. [Online]. Disponible: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8711251/>

- [9] F. Wang, T. W. Oh, C. Vergara-Niedermayr, T. Kurc, and J. Saltz, “Managing and querying whole slide images,” vol. 8319, p. 83190J. [Online]. Disponible: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3405921/>
- [10] B. Elesedy and S. Zaidi, “Provably strict generalisation benefit for equivariant models.” [Online]. Disponible: <http://arxiv.org/abs/2102.10333>
- [11] A. H. Song, G. Jaume, D. F. K. Williamson, M. Y. Lu, A. Vaidya, T. R. Miller, and F. Mahmood, “Artificial intelligence for digital and computational pathology,” vol. 1, no. 12, pp. 930–949, number: 12 Publisher: Nature Publishing Group. [Online]. Disponible: <https://www.nature.com/articles/s44222-023-00096-8>
- [12] V. Baxi, R. Edwards, M. Montalto, and S. Saha, “Digital pathology and artificial intelligence in translational medicine and clinical practice,” vol. 35, no. 1, pp. 23–32.
- [13] C. McGenity and D. Treanor, “Navigating the reporting guideline environment for computational pathology: A review.” [Online]. Disponible: <http://arxiv.org/abs/2301.09985>
- [14] G. Vergheze, J. K. Lennerz, D. Ruta, W. Ng, S. Thavaraj, K. P. Siziopikou, T. Naidoo, S. Rane, R. Salgado, S. E. Pinder, and A. Grigoriadis, “Computational pathology in cancer diagnosis, prognosis, and prediction – present day and prospects,” vol. 260, no. 5, pp. 551–563. [Online]. Disponible: <https://pathsocjournals.onlinelibrary.wiley.com/doi/10.1002/path.6163>
- [15] I. Chatterjee, *Machine Learning and Its Application: A Quick Guide for Beginners*. BENTHAM SCIENCE PUBLISHERS. [Online]. Disponible: <https://www.eurekaselect.com/199239/volume/1>
- [16] K. Lindman, J. F. Rose, M. Lindvall, C. Lundström, and D. Treanor, “Annotations, ontologies, and whole slide images – development of an annotated ontology-driven whole slide image library of normal and abnormal human tissue,” vol. 10, p. 22. [Online]. Disponible: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6669998/>
- [17] L.-H. Lim and B. J. Nelson, “What is an equivariant neural network?” [Online]. Disponible: <http://arxiv.org/abs/2205.07362>
- [18] G. Cesa, L. Lang, and M. Weiler, “A program to build e(n)-equivariant steerable CNNs.” [Online]. Disponible: <https://openreview.net/forum?id=WE4qe9xlnQw>
- [19] R. Kondor and S. Trivedi, “On the generalization of equivariance and convolution in neural networks to the action of compact groups.” [Online]. Disponible: <http://arxiv.org/abs/1802.03690>
- [20] T. S. Cohen and M. Welling, “Group equivariant convolutional networks.” [Online]. Disponible: <http://arxiv.org/abs/1602.07576>
- [21] —, “Steerable CNNs.” [Online]. Disponible: <http://arxiv.org/abs/1612.08498>

- [22] W. Freeman and E. Adelson, “The design and use of steerable filters,” vol. 13, no. 9, pp. 891–906, conference Name: IEEE Transactions on Pattern Analysis and Machine Intelligence. [Online]. Disponible: <https://ieeexplore.ieee.org/document/93808>
- [23] M. Weiler, P. Forré, E. Verlinde, and M. Welling, “Coordinate independent convolutional networks – isometry and gauge equivariant convolutions on riemannian manifolds.” [Online]. Disponible: <http://arxiv.org/abs/2106.06020>
- [24] E. J. Bekkers, M. W. Lafarge, M. Veta, K. A. Eppenhof, J. P. Pluim, and R. Duits, “Roto-translation covariant convolutional networks for medical image analysis.” [Online]. Disponible: <http://arxiv.org/abs/1804.03393>
- [25] B. S. Veeling, J. Linmans, J. Winkens, T. Cohen, and M. Welling. Rotation equivariant CNNs for digital pathology. [Online]. Disponible: <https://arxiv.org/abs/1806.03962v1>
- [26] Y. Li, G. Cao, and W. Cao, “A dynamic group equivariant convolutional networks for medical image analysis,” in *2020 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, pp. 1056–1062. [Online]. Disponible: <https://ieeexplore.ieee.org/document/9313601>
- [27] WMA - the world medical association-declaración de helsinki de la AMM – principios éticos para las investigaciones médicas en seres humanos. [Online]. Disponible: <https://www.wma.net/es/policies-post/declaracion-de-helsinki-de-la-amm-principios-eticos-para-las-investigaciones-medicas-en-seres-humanos/>
- [28] Council for International Organizations of Medical Sciences (CIOMS), “International ethical guidelines for health-related research involving humans.” [Online]. Disponible: <https://cioms.ch/publications/product/international-ethical-guidelines-for-health-related-research-involving-humans/>